

# Detecção de objetos

Fernando Pujaico Rivera

## 1 Otimização dos parâmetros do sistema

Como já foi visto em seções anteriores, para obter um ponto  $P = (x, y, z)$  em 3D a partir de um ponto  $p = (c_0, d_0, b_0)$  extraído a partir de imagens em 2D, é usada a função  $P \leftarrow func\_3d(p; \mathbf{K})$ , sendo  $\mathbf{K} = [h_0, D, \theta, f, g]^T$  um vetor que contem os parâmetros da geometria do sistema. Porém, os valores em  $\mathbf{K} \in \mathbb{R}^4$  inicialmente são medidos manualmente, e precisam ser ajustados a sus valores reais, ou o mais próximos a estos que seja possível; para cumprir este proposito podemos usar a função  $func\_z()$  que é uma simplificação da função  $func\_3d()$  onde

$$z \leftarrow func\_z(\{c_0, d_0\}; \mathbf{K}), \quad (1)$$

$$\hat{p} = \{c_0, d_0\} \xrightarrow[\mathbf{K}]{func\_z} z; \quad (2)$$

de modo que o cálculo da altura  $z$ , mediante a função  $func\_z()$ , só depende dos valores  $\hat{p} = \{c_0, d_0\}$  e  $\mathbf{K}$ .

$$func\_z(\hat{p}; \mathbf{K}) = \frac{D \operatorname{tg}(\theta) \left[ 1 + \operatorname{ctg} \left( \theta + \operatorname{atg} \left( \frac{h_0}{d_0 + c_0} \right) \right) \operatorname{ctg} \left( \theta - \operatorname{atg} \left( \frac{d_0}{h_0} \right) \right) \right]}{\left[ 1 + \operatorname{ctg} \left( \theta + \operatorname{atg} \left( \frac{h_0}{d_0 + c_0} \right) \right) \operatorname{ctg}(\alpha) \right]}, \quad (3)$$

$$\operatorname{ctg}(\alpha) = \frac{D \operatorname{tg}(\theta) \operatorname{ctg} \left( \theta - \operatorname{atg} \left( \frac{d_0}{h_0} \right) \right) - f}{g}. \quad (4)$$

Usando todos estes antecedentes, nosso interesse é encontrar  $\mathbf{K}$  com o valor mais ajustado a realidade; é dizer com valores otimizados, com este fim são processados, e convertidas a imagens binarias, um conjunto de objetos de tamanho conhecido, obtendo  $L$  dados  $\hat{p}_l$  e  $z_l$ ,  $\forall 1 \leq l \leq L$ . Onde  $z_l$

são as alturas dos objetos e  $\hat{p}_l$  são os dados extraídos do objeto nas imagens binárias; com a informação destes dois âmbitos (3D e 2D respetivamente) definimos a função de custo  $e(\mathbf{K})$ ,

$$e(\mathbf{K}) = \sum_{l=1}^L (z_l - \text{func\_}z(\hat{p}_l; \mathbf{K}))^2. \quad (5)$$

Assim, se os valores  $\mathbf{K}$ ,  $\hat{p}_l$  e  $z_l$ , são medidos ou obtidos de forma exata,  $e(\mathbf{K})$  deveria ser igual a zero, devido a que  $z_l \approx \text{func\_}z(\hat{p}_l; \mathbf{K})$ ; porem, como na prática usamos medidas e cálculos aproximados, nosso objetivo mais eficiente é achar o vetor  $\mathbf{K} = \bar{\mathbf{K}}$  que minimiza  $e(\mathbf{K})$ .

Para facilitar o cálculo deste mínimo é conveniente expressar a Equação (5) na forma matricial como na Equação (6)

$$e(\mathbf{K}) = \|\mathbf{Z} - \mathbf{F}(\mathbf{K})\|^2, \quad (6)$$

onde  $\mathbf{Z} \in \mathbb{R}^L$  é um vetor coluna,  $\mathbf{F}(\mathbf{K}) : \mathbb{R}^4 \rightarrow \mathbb{R}^L$  é uma função vetorial de variável vetorial  $\mathbf{K}$ , e o operador  $\|\cdot\|^2$  indica a norma ao quadrado do vetor,

$$\mathbf{Z} = \begin{bmatrix} z_1 \\ z_2 \\ \vdots \\ z_l \\ \vdots \\ z_L \end{bmatrix}, \quad \mathbf{F}(\mathbf{K}) = \begin{bmatrix} \text{func\_}z(\hat{p}_1; \mathbf{K}) \\ \text{func\_}z(\hat{p}_2; \mathbf{K}) \\ \vdots \\ \text{func\_}z(\hat{p}_l; \mathbf{K}) \\ \vdots \\ \text{func\_}z(\hat{p}_L; \mathbf{K}) \end{bmatrix}. \quad (7)$$

Assim, para minimizar a Equação (6) podemos aplicar o “algoritmo de Levenberg-Marquardt” (LMA o simplesmente LM), tambem conhecido como o “método de mínimos quadrados amortiguados” (DLS) [1, pp. 232-234]. De modo que o vetor  $\bar{\mathbf{K}}$  que minimiza a Equação (6) é calculado iterativamente usando a Equação (8)

$$\mathbf{K}_{i+1} \leftarrow \mathbf{K}_i + [\mathbf{J}(\mathbf{K}_i)^T \mathbf{J}(\mathbf{K}_i) + \alpha \mathbf{I}]^{-1} \mathbf{J}(\mathbf{K}_i)^T [\mathbf{Z} - \mathbf{F}(\mathbf{K}_i)], \quad (8)$$

onde  $\mathbf{I}$  é uma matriz identidade de  $4 \times 4$ , a variável  $\alpha \geq 0$  é um fator de regularização escolhido por nos, cujo propósito é conseguir que a matriz

$[\mathbf{J}(\mathbf{K}_i)^T \mathbf{J}(\mathbf{K}_i) + \alpha \mathbf{I}]$  sempre tenha inversa, e  $\mathbf{J}(\mathbf{K}) \in \mathbb{R}^{L \times 4}$  é a matriz jacobiana [3, pp. 130] de  $\mathbf{F}(\mathbf{K})$ ; é dizer

$$\mathbf{J}(\mathbf{K}) = \frac{\partial \mathbf{F}(\mathbf{K})}{\partial \mathbf{K}^T} = \begin{bmatrix} \frac{\partial func\_z(\hat{p}_1; \mathbf{K})}{\partial \mathbf{K}^T} \\ \frac{\partial func\_z(\hat{p}_2; \mathbf{K})}{\partial \mathbf{K}^T} \\ \vdots \\ \frac{\partial func\_z(\hat{p}_L; \mathbf{K})}{\partial \mathbf{K}^T} \end{bmatrix}, \quad (9)$$

$$\frac{\partial func\_z(\hat{p}; \mathbf{K})}{\partial \mathbf{K}^T} \equiv \begin{bmatrix} \frac{\partial func\_z(\hat{p}; \mathbf{K})}{\partial h_0} & \frac{\partial func\_z(\hat{p}; \mathbf{K})}{\partial D} & \frac{\partial func\_z(\hat{p}; \mathbf{K})}{\partial \theta} & \frac{\partial func\_z(\hat{p}; \mathbf{K})}{\partial f} & \frac{\partial func\_z(\hat{p}; \mathbf{K})}{\partial g} \end{bmatrix}. \quad (10)$$

Finalmente a Equação (8) converge a um vetor  $\mathbf{K}_{i+1}$  que é um mínimo global de  $e(\mathbf{K})$ , se iniciamos o cálculo iterativo desde um valor  $\mathbf{K}_0$  próximo à solução, neste caso são usados os valores  $\{h_0, D, \theta, f, g\}$  medidos ou calculados manualmente. As iterações finalizam quando  $\mathbf{K}_{i+1} \approx \mathbf{K}_i$  onde se declara que o valor ótimo  $\bar{\mathbf{K}} \equiv \mathbf{K}_{i+1}$ .

Sobre o cálculo das derivadas parciais da função  $func\_z(\hat{p}; \mathbf{K})$  em relação a  $\mathbf{K}$ , como descrito na Equação (10), é fácil observar que estes cálculos são possíveis porem extremadamente laboriosos; por este motivo foi usado o motor de cálculo simbólico e sistema de álgebra computacional: Maxima [2]. Assim, com a ajuda desse software é calculado de forma simbólica as derivadas parciais da função  $func\_z(\hat{p}; \mathbf{K})$  em relação a  $\mathbf{K}$ .

Todo o processo de otimização antes descrito pode ser sistematizado mediante o diagrama de blocos da Figura 1, onde podemos ver 3 entradas de dados e uma saída, que neste caso é o valor de  $\mathbf{K} = \bar{\mathbf{K}}$  que minimiza  $e(\mathbf{K})$ .




Figure 1: Algoritmo de Levenberg-Marquardt.

## References

- [1] A. Doicu, T. Trautmann, and F. Schreier. *Numerical Regularization for Atmospheric Inverse Problems*. Springer Praxis Books. Springer Berlin Heidelberg, 2010. ISBN: 9783642054396. URL: [https://books.google.com.br/books?id=P\\_tYXLtQ5x8C](https://books.google.com.br/books?id=P_tYXLtQ5x8C).
- [2] Bruna Santos. “Introdução ao software maxima”. In: *Centro de Matemática da Universidade do Porto* (2009).
- [3] X.D. Zhang. *Matrix Analysis and Applications*. Cambridge University Press, 2017. ISBN: 9781108417419. URL: <https://books.google.com.br/books?id=YBsODwAAQBAJ>.