Detecção de objetos

Fernando Pujaico Rivera

1 Otimização dos parâmetros do sistema

Como já foi visto em seções anteriores, para obter um ponto $P = (x, y, z)$ em 3D a partir de um ponto $p = (c_0, d_0, b_0)$ extraído a partir de imagens em 2D, é usada a função $P \leftarrow func\_3d(p; \mathbf{K})$, sendo $\mathbf{K} = [h_0, D, \theta, f, g]^T$ um vetor que contem os parâmetros da geometria do sistema. Porem, os valores em $\mathbf{K} \in \mathbb{R}^4$ inicialmente são medidos manualmente, e precisam ser ajustados a sus valores reais, ou o mais próximos a estos que seja possível; para cumprir este proposito podemos usar a função $func\_z()$ que é uma simplificação da função $func\_3d()$ onde

$$z \leftarrow func\_z(\{c_0, d_0\}; \mathbf{K}), \tag{1}$$

$$\hat{p} = \{c_0, d_0\} \quad \xrightarrow[\mathbf{K}]{func\_z} \quad z; \tag{2}$$

de modo que o cálculo da altura z, mediante a função $func\_z()$, só depende dos valores $\hat{p} = \{c_0, d_0\}$ e $\mathbf{K}$.

$$func\_z(\hat{p}; \mathbf{K}) = \frac{D\ tg(\theta)\left[1 + ctg\left(\theta + atg\left(\frac{h_0}{d_0+c_0}\right)\right) ctg\left(\theta - atg\left(\frac{d_0}{h_0}\right)\right)\right]}{\left[1 + ctg\left(\theta + atg\left(\frac{h_0}{d_0+c_0}\right)\right) ctg(\alpha)\right]}, \tag{3}$$

$$ctg(\alpha) = \frac{D\ tg(\theta) ctg\left(\theta - atg\left(\frac{d_0}{h_0}\right)\right) - f}{g}. \tag{4}$$

Usando todos estes antecedentes, nosso interesse é encontrar $\mathbf{K}$ com o valor mais ajustado a realidade; é dizer com valores optimizados, com este fim são processados, e convertidas a imagens binarias, um conjunto de objetos de tamanho conhecido, obtendo L dados $\hat{p}_l$ e z_l, $\forall\ 1 \leq l \leq L$. Onde z_l

são as alturas dos objetos e $\hat{p}_l$ são os dados extraídos do objeto nas imagens binarias; com a informação destes dois âmbitos (3D e 2D respetivamente) definimos a função de custo $e\left(\mathbf{K}\right)$,

$$e\left(\mathbf{K}\right) = \sum_{l=1}^{L} \left(z_l - func\_z(\hat{p}_l; \mathbf{K})\right)^2 . \tag{5}$$

Assim, se os valores $\mathbf{K}$, $\hat{p}_l$ e z_l, são medidos ou obtidos de forma exata, $e\left(\mathbf{K}\right)$ deveria ser igual a zero, devido a que $z_l \approx func\_z(\hat{p}_l; \mathbf{K})$; porem, como na prática usamos medidas e cálculos aproximados, nosso objetivo mais eficiente é achar o vetor $\mathbf{K} = \bar{\mathbf{K}}$ que minimiza $e\left(\mathbf{K}\right)$.

Para facilitar o cálculo deste mínimo é conveniente expressar a Equação (5) na forma matricial como na Equação (6)

$$e\left(\mathbf{K}\right) = ||\mathbf{Z} - \mathbf{F}(\mathbf{K})||^2, \tag{6}$$

onde $\mathbf{Z} \in \mathbb{R}^L$ é um vetor coluna, $\mathbf{F}(\mathbf{K}) : \mathbb{R}^4 \to \mathbb{R}^L$ é uma função vetorial de variável vetorial $\mathbf{K}$, e o operador $||.||^2$ indica a norma ao quadrado do vetor,

$$\mathbf{Z} = \begin{bmatrix} z_1 \\ z_2 \\ \vdots \\ z_l \\ \vdots \\ z_L \end{bmatrix}, \qquad \mathbf{F}(\mathbf{K}) = \begin{bmatrix} func\_z(\hat{p}_1; \mathbf{K}) \\ func\_z(\hat{p}_2; \mathbf{K}) \\ \vdots \\ func\_z(\hat{p}_l; \mathbf{K}) \\ \vdots \\ func\_z(\hat{p}_L; \mathbf{K}) \end{bmatrix}. \tag{7}$$

Assim, para minimizar a Equação (6) podemos aplicar o "algoritmo de Levenberg-Marquardt" (LMA o simplesmente LM), tambem conhecido como o "método de mínimos quadrados amortiguados" (DLS) [1, pp. 232-234]. De modo que o vetor $\bar{\mathbf{K}}$ que minimiza a Equação (6) é calculado iterativamente usando a Equação (8)

$$\mathbf{K}_{i+1} \leftarrow \mathbf{K}_i + \left[\mathbf{J}(\mathbf{K}_i)^T \mathbf{J}(\mathbf{K}_i) + \alpha \mathbf{I}\right]^{-1} \mathbf{J}(\mathbf{K}_i)^T \left[\mathbf{Z} - \mathbf{F}(\mathbf{K}_i)\right], \tag{8}$$

onde $\mathbf{I}$ é uma matriz identidade de 4×4, a variável $\alpha \geq 0$ é um fator de regularização escolhido por nos, cujo propósito é conseguir que a matriz

$\left[\mathbf{J}(\mathbf{K}_i)^T\mathbf{J}(\mathbf{K}_i) + \alpha\mathbf{I}\right]$ sempre tenha inversa, e $\mathbf{J}(\mathbf{K}) \in \mathbb{R}^{L\times 4}$ é a matriz jacobiana [3, pp. 130] de $\mathbf{F}(\mathbf{K})$; é dizer

$$\mathbf{J}(\mathbf{K}) = \frac{\partial \mathbf{F}(\mathbf{K})}{\partial \mathbf{K}^T} = \begin{bmatrix} \frac{\partial func\_z(\hat{p}_1;\mathbf{K})}{\partial \mathbf{K}^T} \\ \frac{\partial func\_z(\hat{p}_2;\mathbf{K})}{\partial \mathbf{K}^T} \\ \vdots \\ \frac{\partial func\_z(\hat{p}_L;\mathbf{K})}{\partial \mathbf{K}^T} \end{bmatrix}, \tag{9}$$

$$\frac{\partial func\_z(\hat{p};\mathbf{K})}{\partial \mathbf{K}^T} \equiv \begin{bmatrix} \frac{\partial func\_z(\hat{p};\mathbf{K})}{\partial h_0} & \frac{\partial func\_z(\hat{p};\mathbf{K})}{\partial D} & \frac{\partial func\_z(\hat{p};\mathbf{K})}{\partial \theta} & \frac{\partial func\_z(\hat{p};\mathbf{K})}{\partial f} & \frac{\partial func\_z(\hat{p};\mathbf{K})}{\partial g} \end{bmatrix}. \tag{10}$$

Finalmente a Equação (8) converge a um vetor $\mathbf{K}_{i+1}$ que é um mínimo global de $e(\mathbf{K})$, se inciamos o cálculo iterativo desde um valor $\mathbf{K}_0$ próximo à solução, neste caso são usados os valores $\{h_0, D, \theta, f, g\}$ medidos o calculados manualmente. As iterações finalizam quando $\mathbf{K}_{i+1} \approx \mathbf{K}_i$ onde se declara que o valor ótimo $\bar{\mathbf{K}} \equiv \mathbf{K}_{i+1}$.

Sobre o cálculo das derivadas parciais da função $func\_z(\hat{p};\mathbf{K})$ em relação a $\mathbf{K}$, como descrito na Equação (10), é fácil observar que estes cálculos são possíveis porem extremadamente laboriosos; por este motivo foi usado o motor de cálculo simbólico e sistema de álgebra computacional: Maxima [2]. Assim, com a ajuda desse software é calculado de forma simbólica as derivadas parciais da função $func\_z(\hat{p};\mathbf{K})$ em relação a $\mathbf{K}$.

Todo o processo de optimização antes descrito pode ser sistematizado mediante o diagrama de blocos da Figura 1, onde podemos ver 3 entradas de dados e uma saída, que neste caso é o valor de $\mathbf{K} = \bar{\mathbf{K}}$ que minimiza $e(\mathbf{K})$.

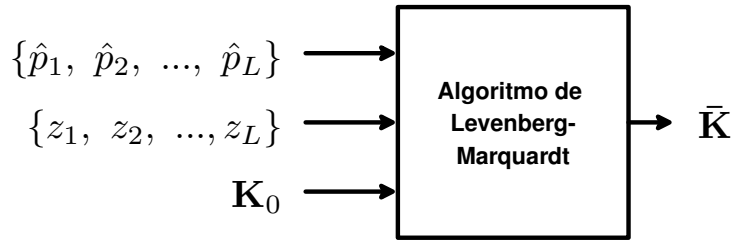

Figure 1: Algoritmo de Levenberg-Marquardt.

References

[1] A. Doicu, T. Trautmann, and F. Schreier. *Numerical Regularization for Atmospheric Inverse Problems*. Springer Praxis Books. Springer Berlin Heidelberg, 2010. ISBN: 9783642054396. URL: https://books.google.com.br/books?id=P_tYXLtQ5x8C.

[2] Bruna Santos. "Introdução ao software maxima". In: *Centro de Matemática da Universidade do Porto* (2009).

[3] X.D. Zhang. *Matrix Analysis and Applications*. Cambridge University Press, 2017. ISBN: 9781108417419. URL: https://books.google.com.br/books?id=YBs0DwAAQBAJ.